



Cours Recherche D'information (Information Retrieval)

3^{ème} Année Licence

Option : ISIL



2023-2024



Mme Z.LAAREDJ

Le modèle probabiliste

Plan

- Introduction
- Rappel des probabilités
- Modèle de tri probabiliste (Probabilistic Ranking Principle)
- Comment estimer les probabilités ?
- Binary Independance Retrieval model
- Modèle probabiliste BIR

Introduction

Pourquoi les probabilités ?

- La RI est un processus incertain et imprécis
 - Imprécision dans l'expression des besoins
 - Incertitude dans la représentation des informations
- La théorie des probabilités semble adéquate pour prendre en compte cette incertitude et imprécision

Introduction

- Le modèle probabiliste est proposé par Robertson et Jones en 1976;
- Il permet d'exprimer une estimation de la probabilité de pertinence d'un document par rapport à une requête.
- Il permet de présenter les documents à l'utilisateur selon l'ordre décroissant de leur probabilité de pertinence

Introduction

- Il existe différentes manières de voir une approche probabiliste de la recherche d'information
- Approche classique : probabilité d'avoir l'événement pertinent sachant un document et une requête.
- Approche par réseaux d'inférence : probabilité que la requête soit vraie d'après une inférence à partir du contenu du document.
- Approche par modèle de langue : probabilité qu'une requête posée soit générée à partir d'un document.

Le modèle probabiliste classique

- Le modèle probabiliste classique consiste à calculer la pertinence d'un document en fonction de pertinences connues pour d'autres documents.
- Ce calcul se fait en estimant la pertinence de chaque index pour un document et en utilisant le Théorème de Bayes et une règle de décision

Rappel des probabilités

➤ Vocabulaire des probabilités

■ **Epreuve aléatoire** : épreuve dans l'issue n'est pas connu par avance autrement dit on a une épreuve mais on save pas le résultat de cet épreuve par exemple le lancé d'un dès.

■ A chaque épreuve aléatoire on a un certain nombres des résultats possibles. Cet ensemble des résultats possibles s'appelle l'univers Ω .

■ Exemple des dès $\Omega = \{1,2,3,4,5,6\}$

Rappel des probabilités

➤ Vocabulaire des probabilités

■ **Événement** : quelque chose spécifique. A est une partie de Ω dont l'ensemble des valeurs de A doivent être prise dans l'univers Ω .

■ Exemple A : « Obtenir un résultat paire c à d $A = \{2,4,6\}$

■ Événement contraire : a chaque événement on peut associé l'évènement contraire notée $\text{non}A$

■ Exemple : comme on a $A = \{2,4,6\}$ donc nécessairement $\text{non}A = \{1,3,5\}$.

Rappel des probabilités

➤ Vocabulaire des probabilités

■ **Événement certain**: c'est l'ensemble des résultats possibles donc l'univers Ω .

■ Exemple des dès : C: « obtenir un résultat inférieur à 8 » donc $C = \{1, 2, 3, 4, 5, 6\}$ donc l'événement certain c'est toujours l'univers Ω .

■ **Événement impossible** : un événement ne contient aucun élément.

■ I: « obtenir un résultat supérieur à 7 » donc $I = \{ \} = \varnothing$

Rappel des probabilités

➤ Vocabulaire des probabilités

■ **Opérations:** deux opérations sont défini :

● Union : $\cup$

● Intersection : $\cap$

Rappel des probabilités

➤ Vocabulaire des probabilités

■ **L'opération d'Union** est défini comme l'union de deux évènements A et B en utilisant le « OU inclusif » et notée comme suit : $A \cup B$

■ **Exemple** : $A = \{2, 4, 6\}$, $B = \{3, 6\}$, $C = \{1, 3\}$,

$A \cup B$: « Obtenir un résultat pair ou multiple de 3 donc :

$$A \cup B = \{2, 3, 4, 6\}$$

$A \cup C$: « Obtenir un résultat pair ou diviseur de 3 donc :

$$A \cup C = \{1, 2, 3, 4, 6\}$$

Rappel des probabilités

■ **L'opération d'Intersection** est défini comme l'intersection de deux évènements A et B en utilisant le « ET » et notée comme suit :

$$A \cap B$$

■ **Exemple** : $A=\{2,4,6\}, B = \{3,6\}, C=\{1,3\},$

$A \cap B$: « Obtenir un résultat pair et multiple de 3 donc :

$$A \cap B = \{6\}$$

$A \cap C$: « Obtenir un résultat pair et diviseur de 3 donc :

$$A \cap C = \{ \} = \varnothing$$

RQ: lorsque l'intersection de deux évènements égale à l'ensemble vide on dit que les deux évènements sont **incompatibles**

Rappel des probabilités

➤ Vocabulaire des probabilités

■ **Cardinale:** c'est le nombre d'éléments d'un évènement par exemple $\text{Card}(A) = 3$

■ $A \cup \text{Non}A = \Omega$

■ $A \cap \text{Non}A = \varnothing$

■ $\text{Card}(A \cup B) = \text{card}A + \text{card}B - \text{card}(A \cap B)$

Rappel des probabilités

➤ Vocabulaire des probabilités

■ **Exemple** : on a une classe de 30 élèves dont 20 élèves étudient anglais, 7 élèves étudient espagnol et 3 élèves étudient les deux langues.

● **Question** : combien d'élèves n'étudient aucune langue ?


Rappel des probabilités

➤ Vocabulaire des probabilités

■ A: événement élèves étudient anglais

■ E : événement élèves étudient espagnol

	E	NonE	Σ
A	3	17	20
NonA	4	6	10
Σ	7	23	30



Rappel des probabilités

➤ Vocabulaire des probabilités

■ A: événement élèves étudient anglais

■ E : événement élèves étudient espagnol

	E	NonE	Σ
A	3	17	20
NonA	4	6	10
Σ	7	23	30



	E	NonE
A	$A \cap E$	$A \cap \text{NonE}$
NonA	$\text{NonA} \cap E$	$\text{NonA} \cap \text{NonE}$

Rappel des probabilités

➤ Vocabulaire des probabilités

■ **La probabilité d'un évènement** : la probabilité d'un évènement notée $P(A)$ est un nombre compris entre 0 et 1, autrement dit :

■ $0 \leq P(A) \leq 1$ et tel que :

1) $P(\Omega) = 1$

2) Si $A \cap B = \emptyset$ alors $P(A \cup B) = P(A) + P(B)$

3) $P(A) = \text{Card}A / \text{Card}\Omega$

= nombre de cas favorables / nombre de cas possibles

■ $P(\text{Non}A) = 1 - P(A)$

■ $P(A \cup B) = P(A) + P(B) - P(A \cap B)$

Rappel des probabilités

➤ **Probabilités conditionnelle:** dans le cas d'existence d'une condition, on parle de probabilité conditionnelle, autrement dit, la probabilité d'avoir un événement sous condition, la probabilité conditionnelle est notée soit :

- $P(B|A)$ ou $P_A(B)$: probabilité d'un événement B sachant A

- $P_A(B) = P(A \cap B) / P(A)$

- Exemple : $P(\text{"retrieval"} \mid \text{"information"}) > P(\text{"retrieval"} \mid \text{"politic"})$

Rappel des probabilités


➤ Théorème de Bayes

- $P(A, B) = P(A \cap B) = P(A | B)P(B) = P(B | A)P(A)$

- $P(A | B) = \frac{P(B | A)P(A)}{P(B)}$ Règle de Bayes

Rappel des probabilités

- **Variable Aléatoire** : un variable aléatoire est une application de l'univers Ω vers l'ensemble des nombres réels
- Deux ensembles sont défini dans le variable aléatoire :
 - L'ensemble de départ est l'univers Ω
 - L'ensemble d'arrivée est l'univers image $X(\Omega)$




Rappel des probabilités

➤ Exemple d'un variable Aléatoire

J'ai une urne qui contient 3 boules rouges et 7 boules bleus. Je tire une boule et je note sa couleur sachant que je dois mise 5 € pour jour. Soit X la variable aléatoire qui associe le gain du joueur.

■ Quel sont les valeurs prises par X ou bien quel est l'univers

image



Modèle de tri probabiliste (Probabilistic Ranking Principle)

➤ Hypothèses


- Une paire (d,q) est la réalisation d'un tirage aléatoire dans un espace document*requête
- A chaque paire, on associe une variable aléatoire binaire R qui vaut 1 si d est pertinent et 0 sinon

➤ Probability Ranking Principle (Robertson 77)

- Présenter les documents à l'utilisateur selon l'ordre décroissant de leur probabilité de pertinence $P(R=1|d,q)$
- Propriété : principe optimal car il optimise le risque de Bayes pour la règle de décision suivante : *d est pertinent ssi $P(R=1|d,q) > P(R=0|d,q)$*

Modèle de tri probabiliste (Probabilistic Ranking Principle)

➤ Pour une requête Q



Avec: $\text{Corpus} = R \cup NR$
 $R \cap NR = \varnothing$

Modèle de tri probabiliste (Probabilistic Ranking Principle)

➤ L'idée principale dans PRP

- Classement des documents par ordre décroissant de probabilité de pertinence
- $P(\text{pertinent} | \text{document}) \longrightarrow P(R|d)$ (ou $P(R=1|d)$)
- On peut aussi estimer de la même façon la probabilité de non pertinence
- $P(\text{Non pertinence} | \text{document}) \longrightarrow P(NR|d)$ (ou $P(R=0|d)$)
- Un document est sélectionné si : $P(R|d) > P(NR|d)$

Modèle de tri probabiliste (Probabilistic Ranking Principle)

➤ L'idée principale dans PRP

■ L'idée de base dans un modèle probabiliste est de tenter de déterminer les probabilités $P(R|d)$ et $P(NR|d)$ pour une requête donnée. Ces deux probabilités signifient respectivement : si on retrouve le document d , quelle est la probabilité qu'on obtient l'information pertinente et non-pertinente.

■ Les documents peuvent être triés selon:

$$RSV(q, d)^{rank} = \frac{P(R | d)}{P(NR | d)}$$

Modèle de tri probabiliste (Probabilistic Ranking Principle)

➤ L'idée principale dans PRP

■ Cependant , les deux probabilités $P(R|d)$ / $P(NR|d)$ ne sont pas directement calculables d'où la nécessité d'utiliser le théorème de Bayes pour les calculer.

■ Le théorème de Bayes

$$P(R | d) = \frac{P(d | R)P(R)}{P(d)}$$

$$P(NR | d) = \frac{P(d | NR)P(NR)}{P(d)}$$

Modèle de tri probabiliste (Probabilistic Ranking Principle)

➤ L'idée principale dans PRP

■ Le théorème de Bayes

- $P(d|R)$ = la probabilité que D fait partie de l'ensemble pertinent,

- $P(R)$ = la probabilité de pertinence, c'est-à-dire, si on choisit un document au hasard dans le corpus, la chance de tomber sur un document pertinent ,

- $P(d)$ = la probabilité que le document soit choisi (si on prend au hasard un document dans le corpus, la chance de tomber sur d).

Comment estimer les probabilités ?

- Comment estimer $P(d|R)$ et $P(d|NR)$?
- Il y a plusieurs hypothèses de calcul en tenant compte de l'indépendance des événements. Parmi celles-ci, il y :
 - BIR (Binary Independance Retrieval model)
 - Two poisson model

Binary Independance Retrieval model

➤ Hypothèses

- Un document est représenté comme un ensemble d'événements $(t_i) : d = (t_1, \dots, t_n)$

- Un événement t_i dénote la présence ou l'absence d'un terme dans le document

- Considérons un document comme une liste de termes

$$RSV(q, d) = \frac{P(d | R)}{P(d | NR)} = \frac{P((t_1, t_2, \dots, t_n) | R)}{P((t_1, t_2, \dots, t_n) | NR)}$$

- En s'appuyant sur l'hypothèse d'indépendance des termes

$$\frac{P(d | R)}{P(d | NR)} = \prod_{i=1}^n \frac{P(t_i | R)}{P(t_i | NR)}$$

Binary Independance Retrieval model

➤ Hypothèses

■ ti peut être vu comme, une variable aléatoire donc :

● Une série de $(t_i = x_i)$ où :

$$x_i = \begin{cases} 1 & \text{terme present} \\ 0 & \text{terme absent} \end{cases}$$

● $P(d|R) = P(t_1=x_1, t_2=x_2, t_3=x_3, \dots |d)$

● $P(d|R) = P(t_1=x_1, t_2=x_2, t_3=x_3, \dots |NR)$

Binary Independance Retrieval model

➤ Hypothèses

$$P(d | R) = \prod_{i=1}^n P(t_i = x_i | R) = \prod_{i=1}^n p_i^{x_i} (1 - p_i)^{(1-x_i)}$$

$$P(d | NR) = \prod_{i=1}^n P(t_i = x_i | NR) = \prod_{i=1}^n q_i^{x_i} (1 - q_i)^{(1-x_i)}$$

Binary Independance Retrieval model

➤ Exemple

Soit un document contient t_1, t_3, t_5 , et que l'ensemble de termes connus du système est $\{t_1, t_2, t_3, t_4, t_5, t_6\}$. Alors:

$$D = (t_1=1, t_2=0, t_3=1, t_4=0, t_5=1, t_6=0).$$

Donc:

$$P(D|R) = P(t_1=1|R) * P(t_2=0|R) * P(t_3=1|R) * P(t_4=0|R) * P(t_5=1|R) * P(t_6=0|R)$$

En appliquant la formule on aura donc:

$$P(D|R) = P(t_1=1|R)^1 * P(t_1=0|R)^0 * P(t_2=1|R)^0 * P(t_2=0|R)^1 * P(t_3=1|R)^1 * P(t_3=0|R)^0 * P(t_4=1|R)^0 * P(t_4=0|R)^1 * P(t_5=1|R)^1 * P(t_5=0|R)^0 * P(t_6=1|R)^0 * P(t_6=0|R)^1$$

Binary Independance Retrieval model

- Après simplification on aura :

$$RSV(d, q) = \sum_{i: x_i=1}^n \log \frac{p_i(1 - q_i)}{q_i(1 - p_i)}$$

- La question clé est donc réduite à l'estimation de $P(t_i = x_i \mid R)$ et $P(t_i = x_i \mid NR)$

Estimation de p_i et q_i

- En considérant pour chaque terme t_i

Documents	Pertinent(R)	Non-pertinent (NR)	Total
$t_i=1$	r	$n-r$	n
$t_i=0$	$R-r$	$N-n-R+r$	$N-n$
Total	R	$N-R$	N

r : nombre de documents pertinents contenant t_i

n : nombre de documents contenant t_i

R : nombre total de documents pertinents

N : nombre de documents dans la collection

Estimation par vraisemblance

➤ On obtient donc :

$$p_i = \frac{r}{R} \quad \text{et} \quad q_i = \frac{n - r}{N - R}$$

➤ La formule globale pour calculer le RSV est :

$$RSV(d, q) = \sum \log \frac{r / (R - r)}{(n - r) / (N - n - R + r)}$$

Modèle probabiliste BIR

- Lisser les probabilités pour éviter 0

$$RSV(q, d) = \sum \log \frac{\frac{r + 0.5}{R - r + 0.5}}{\frac{(n - r + 0.5)}{(N - n - R + r + 0.5)}}$$

Estimation sans données d'apprentissage

- Estimation de p_i
 - Constante (Croft & Harper 79)
 - Proportionnel à la probabilité d'occurrence du terme dans la collection (n/N)
- Estimation de q_i
 - Prendre tous les documents ne comportant pas t_i

$$RSV(Q, D) \approx \sum_{i=1, d_i=k_i=1}^{Rank} \log \frac{N - n_i + 0.5}{n_i + 0.5}$$

$$IDF' = \log \frac{N - n_i}{n_i}$$

Avantages et inconvénients du modèle BIR

➤ Avantages

- Formalisation puissante
- Modélisation explicite de la notion de pertinence

➤ Inconvénients

- La fréquence des termes n'est pas prise en compte
- Difficulté d'estimer les probabilités sans données d'apprentissage
- Hypothèse d'indépendance entre termes souvent critiquée ...mais pas d'amélioration significative pour les modèles qui considèrent cette dépendance

Modèle probabiliste par réseau d'inférence

- Vient du domaine de l'intelligence artificielle
- Idée: Calculer la probabilité d'avoir la requête en fonction des documents $P(Doc \rightarrow Query)$: combinaison d'évidences
- Réseau d'inférence
 - Nœuds: variables
 - Arcs: dépendances

Modèle probabiliste par réseau d'inférence

➤ Exemple

■ Notation $X = \text{true} \equiv x$ $X = \text{false} \equiv \bar{x}$


■ Inférence incertaine

$$P(d) = P(d / bc).P(b).P(c) + P(d / \bar{b}c).P(\bar{b}).P(c) \\ + P(d / b\bar{c}).P(b).P(\bar{c}) + P(d / \bar{b}\bar{c}).P(\bar{b}).P(\bar{c})$$

■ Avec

$$P(b) = P(b / a).P(a) + P(b / \bar{a}).p(\bar{a})$$

$$P(\bar{b}) = P(\bar{b} / a).p(b) + P(\bar{b} / \bar{a}).p(\bar{b})$$




Modèle probabiliste par réseau d'inférence

➤ Pour la RI

■ Nœuds binaires

■ Exemple



Modèle probabiliste par réseau d'inférence

➤ Inférence

$$\begin{aligned} \text{prob}(d \rightarrow q) = \text{prob}(q) = & \text{prob}(q / q_1 q_2) \cdot p(q_1) \cdot p(q_2) + \text{prob}(q / \bar{q}_1 q_2) \cdot p(\bar{q}_1) \cdot p(q_2) \\ & + \text{prob}(q / q_1 \bar{q}_2) \cdot p(q_1) \cdot p(\bar{q}_2) + \text{prob}(q / \bar{q}_1 \bar{q}_2) \cdot p(\bar{q}_1) \cdot p(\bar{q}_2) \end{aligned}$$

Exemple:

- $P(D) = 1/|\text{Corpus}|$
- $P(t_i/D) = t_{fi,D} \cdot \text{idfi}$ si lien avec D, et $p(t_i)=0$ sinon
- $P(q_j/t_i)=1$ si lien, et $p(q_i) = 0$ sinon
- Opérateurs pour les Q_i avec #and, #or, ...
- $P(Q/Q_k)=1$

Limites du modèle probabiliste par réseau d'inférence

- Plutôt un cadre de RI, pas un modèle théorique fort.
- Problème des probabilités de départ non résolu théoriquement (en fait tf.idf...)
- Implantation rapide possible

Le modèle de langue

- Le modèle probabiliste par modèle de langue est proposé par Ponte, Croft et Hiemstra, en 1998-1999
- Vient du domaine de la reconnaissance de parole
- Idée : Utilisation de techniques statistiques pour estimer à la fois les modèles des documents et le score du document pour une requête
- Qu'est-ce qu'un modèle de documents ?
 - Un document est un « sac de mots »
 - Un modèle de langue pour un document est une fonction de probabilité de ces mots du vocabulaire d'indexation

Le modèle de langue

➤ Modèles linguistiques

- Probabilité P d'occurrence d'un mot ou d'une séquence de mots dans une langue

- Etant donné une séquence s composée des mots : $m_1, m_2, \dots, m_l$.

- La probabilité $P(s)$ peut être calculée par

$$P(s) = \prod_{i=1}^l P(m_i / m_1 \dots m_{i-1})$$

- Pour des raisons de complexité, on simplifie en ne prenant que $n-1$ prédécesseurs d'un mot (appelé modèle *n-gramme*)

$$P(m_i / m_1 \dots m_{i-1}) = P(m_i / m_{i-n+1} \dots m_{i-1})$$

Le modèle de langue

➤ Modèles linguistiques

Uni-gramme $P(s) = \prod_{i=1}^l P(m_i)$

Bi-Gramme $P(s) = \prod_{i=1}^l P(m_i / m_{i-1}) = \prod_{i=1}^l \frac{P(m_{i-1} m_i)}{P(m_{i-1})}$

Tri-Grammes $P(s) = \prod_{i=1}^l P(m_i / m_{i-2} m_{i-1}) = \prod_{i=1}^l \frac{P(m_{i-2} m_{i-1} m_i)}{P(m_{i-2} m_{i-1})}$

Le modèle de langue

- Estimation de $P(\alpha)$ sur un corpus de documents (en fait $P(\alpha/C)$, mais notation simplifiée)
- α égal à mi (unigramme), $mi-1\ mi$ (bigramme), ou $mi-2\ mi-1\ mi$ (trigramme)
- Maximum Likelihood:
$$P_{ML}(\alpha) = \frac{|\alpha|}{\sum_{\alpha_j \in C} |\alpha_j|}$$
- Avec :

α_j n-gramme de même taille de α
 C corpus de document

Le modèle de langue

- Pour des n-grammes α' non-rencontrés dans C, les $P(\alpha')$ sont nuls et donc les $P(s)$ qui contiennent ce α' aussi... pas acceptable dans la réalité
 - Solution: Lissage des probabilités
 - Redistribuer une partie de masse de probabilité vers des n-grammes non rencontrés dans C
 - Exemple de lissage : Interpolation (Jelinek Mercier)

$$P_{JM}(m_i / m_{i-1}) = \lambda_{m_{i-1}} \cdot P_{ML}(m_i / m_{i-1}) + (1 - \lambda_{m_{i-1}}) \cdot P_{ML}(m_i)$$

» Avec $\lambda_{m_{i-1}}$ normalisation (possiblement identique pour tous les mots)

Le modèle de langue

➤ Application à la RI

■ Modèle de Hiemstra idée est que :

$$\begin{aligned} \text{Score}(D, Q) &= P(D / Q) = P(D / t_1 t_2 \dots t_n) \\ &= P(D) \frac{P(t_1 t_2 \dots t_n / D)}{P(t_1 t_2 \dots t_n)} \end{aligned}$$

Avec : $Q = t_1 t_2 \dots t_n$

■ Hypothèses

- Les termes de la requête sont indépendants
- $P(t_1 t_2 \dots t_n) = 1/c$

Le modèle de langue

➤ On obtient donc :

$$\log\text{-Score}(D, Q) \propto \sum_{t_i \in Q} \log\left(\alpha_1 \cdot \frac{tf(t_i)}{\sum_t tf(t)} \cdot \frac{\sum_t df(t)}{(1 - \alpha_1) \cdot df(t_i)} + 1\right)$$

Références bibliographiques

- [1] https://www.irit.fr/~Mohand.Boughanem/slides/RI/chap6_modeles_probabilistes.pdf
- [2] https://miashs-www.u-ga.fr/prevert/SpecialiteIHS/RI/cours_RI.pdf
- [3] http://www.iro.umontreal.ca/~nie/IFT6255/Modeles_Probabilistes.html
- [4] https://www.iro.umontreal.ca/~nie/IFT6255/modele_langue.pdf